논문 수정 가이드

「중앙 서버 없는 프라이버시 보존 수직 연합학습 기반 수면무호흡증 예측」

현재 구현(병원별 SPU 학습 · HEaaN2 추론) 반영 · 2026-10-12

0. 요약

원고(2026-10-07 판)는 이전 구현을 기준으로 쓰였다. 이후 구현이 바뀌어 원고와 맞지 않는 부분이 여섯 곳 생겼다. 대부분은 원고가 '한계'나 '남은 과제'로 적어 둔 항목이 해결된 것이라, 고치면 논문의 주장이 더 강해진다.

- **DP 노이즈 위치:** 그래디언트 공개 "후" → SPU 내부에서 공개 "전". 원고의 가장 큰 한계(Sect. 6.4, 8, Impact Statement)가 해소되었다.
- **손실·그래디언트:** MSE 의 자동미분 $g = (2/B)(\hat{y}-y)\sigma'(z)$ → BCE 형 그래디언트 $g = (\sigma(\mathrm{clip}(z,-4,4))-y)/B$. 평문 대비 정확도 손실이 6.2%p 에서 0.6%p 로 줄었다.
- **공개되는 평문:** L 과 g → 노이즈가 섞인 g와 평가 시점의 테스트 정확도 스칼라뿐이다. L 은 기본적으로 공개하지 않는다.
- **데이터·특성:** n = 1,266, 15 개 특성 → n = 5,356, 14 개 특성. P2 는 4 개 특성이고 sleep latency 는 제외되었다.
- **실행 구조:** 단일 프로세스 시뮬레이션 → 병원별 독립 프로세스(SecretFlow 프로덕션 모드, 병원당 포트 2 개). '중앙 서버 없음'이 구현으로 뒷받침된다.
- **추론:** CKKS 라이브러리를 HEaaN2 로 확정했다. 학습 결과를 HEAAN2_LINEAR_V1 텍스트 모델로 내보내며, 집계는 클라이언트가 한다.

1. 원고와 현재 구현의 차이

항목	원고 기술	현재 구현	수정 위치
데이터	SHHS1, n = 1,266	SHHS1 + 이벤트 XML(desat), n = 5,356 (양성 45.0%) train 4,284 / test 1,072 (test 양성 465)	7.1, Table 9
특성	15개, 기관당 5개	14개. P1 5개, P2 4개, P3 5개	Abstract, 3.3, 6.1, Table 5
P2 특성	총 수면, 효율, 깊은 수면, WASO, sleep latency	slpprdp, slpeffp, times34p, waso (sleep latency 제외)	Table 5, Fig. 1
라벨 입력	랜덤 덧셈 share $\Sigma\, y^{(i)}$	P2(PSG 기관)가 y를 .to(spu)로 입력 → SPU가 ABY3 share로 분할	6.2, Table 6, 5.2(ii)

항목	원고 기술	현재 구현	수정 위치
그래디언트	$g = (2/B)(\hat{y}-y)\sigma'(z)$	$g = (\sigma(\text{clip}(z,-4,4)) - y)/B$ (custom VJP, 손실값은 모니터링용 MSE)	3.3 식 (3), Table 4, App. C
logit 범위	입력 스케일로 $\|z\|$ 관리	SPU 내부 clip(z, −4, 4)	4.3
DP 노이즈	공개 후 기관별 $N(0, \sigma^2)$	기관별 $N(0, \sigma^2/3)$ 조각을 SPU에 입력, 합을 g에 더한 뒤 공개	Abstract, 6.2, 6.4, Alg. 1, 8
손실 L	모니터링용으로 공개	기본은 비공개 (--reveal-loss일 때만 공개)	6.4, Table 6, Fig. 1
평가	명시 없음	테스트 정확도를 SPU 안에서 계산하고 스칼라만 공개	Table 6, 7.1
실행 구조	명시 없음	병원별 독립 프로세스, 병원당 2포트 (SecretFlow gRPC + SPU brpc)	6장 신설 절
표준화	명시 없음	기관별 로컬 StandardScaler (열 단위)	7.1
추론	CKKS(라이브러리 미정), Peers가 합산	HEaaN2, 클라이언트가 암호문 상태로 합산 후 복호화	6.3, Alg. 2, 7.3
성능	Acc 0.832, AUC 0.921	Acc 0.891, AUC 0.960 (같은 분할의 평문 0.897 / 0.965)	Abstract, 1, 7.2, 8, Table 7·9

2. 학습 파트 수정

2.1 손실과 그래디언트 (Sect. 3.3, 4.2, 4.3, App. C)

원고의 식 (3)은 MSE를 자동미분한 그래디언트이다. 이 식에는 $\sigma'(z) = 0.197 - 0.012z^2$가 곱해진다. 그래서 $|z|$가 커지면 그래디언트가 0에 가까워지거나(학습 정체) 부호가 뒤집혀 정확도가 크게 떨어졌다. 현재 구현은 그래디언트를 직접 지정한다.

> 식 (3) 대체안: $L = (1/B)\,\Sigma_n\,(\sigma(\tilde{z}^{(n)}) - y^{(n)})^2$ (모니터링용, 공개하지 않음), $g^{(n)} = (1/B)(\sigma(\tilde{z}^{(n)}) - y^{(n)})$, $\tilde{z} = \text{clip}(z, -4, 4)$.
>
> 설명 문장: g는 L의 도함수가 아니라 BCE + 정확한 시그모이드의 그래디언트 $(\sigma(z) - y)/B$에서 σ를 $\sigma\circ\text{clip}$으로 바꾼 것이다. 이렇게 하면 log와 exp 없이 BCE와 같은 방향의 갱신을 얻는다. clip은 ABY3의 비교 연산으로 SPU에서 계산된다.

Table 4 '손실' 행을 다음과 같이 고친다. 학습(SPU) 열: "BCE형 그래디언트 $(\sigma(\text{clip } z) - y)/B$. 손실값은 계산하되 공개하지 않음." 바꾼 이유 열: "log·exp 회피, σ' 소실·부호 반전 방지."

Sect. 4.3은 "입력 스케일을 관리해야 한다"를 "SPU 내부에서 z를 [−4, 4]로 clip한다"로 바꾼다. 이렇게 하면 σ가 항상 단조 증가 구간에서 계산된다. 단, 출력 범위는 $[\sigma(-4), \sigma(4)] \approx [-0.032, 1.032]$이므로 (0, 1)을 약간 벗어나는 점은 그대로 적는다.

임계값 논증도 단순해진다. $|\hat{z}| \le 4$에서 $0.197 - 0.004\hat{z}^2 \ge 0.133 > 0$이므로 $\sigma(\hat{z}) \ge 0.5 \Leftrightarrow \hat{z} \ge 0 \Leftrightarrow z \ge 0$이다. 따라서 원고의 "|z| < 7.02" 조건 없이 모든 z에서 학습(σ)과 추론(σ)의 0.5 판정이 같다.

반드시 함께 적을 실패 사례: clip 없이 σ'에 하한만 둔 변형(bce_safe)은 50 에폭 이후 발산했다. |z| > 약 7에서 σ가 음수가 되어 그래디언트가 z를 더 키우는 양의 되먹임이 생기기 때문이다. 테스트 정확도는 0.833(50 에폭)에서 0.719(100 에폭)로 떨어졌다. 이 결과가 clip이 필요한 근거가 된다.

2.2 DP 노이즈를 SPU 내부로 (Sect. 6.2, 6.4, Alg. 1)

현재 구현은 원고가 '남은 과제'로 적은 방식 그대로이다. 각 기관 i가 $n_i \sim N(0, \sigma^2/3)$을 로컬에서 뽑아 SPU에 share로 넣는다. SPU 안에서 $\tilde{g} = g + \Sigma_i n_i$를 만든 뒤에야 각 기관에 공개한다.

원고에서 지워야 할 문장은 다음과 같다. Abstract의 "현재 구현은 공개 이후에 노이즈를 더하므로", Sect. 6.4의 'DP 노이즈 적용 위치' 단락, Sect. 8 첫 단락의 "단, 현재 구현은…", '남은 과제'의 첫 항목 앞부분, Impact Statement의 "노이즈 위치 수정".

대신 새로 정확히 적어야 할 성질이 세 가지 있다. 이 부분을 빼면 심사에서 지적받기 쉽다.

- **자기 노이즈 조각은 보호가 안 된다.** 기관 i는 자기 n_i를 알기 때문에, 기관 i 입장에서 남는 노이즈는 $N(0, 2\sigma^2/3)$이다(표준편차 0.82σ). 노이즈 강도는 이 값으로 적는다.
- **신호 대비 노이즈 크기를 적는다.** $|\sigma(\hat{z}) - y| \le 1.032$ 이므로 $|g| \le 1.032/B \approx 0.0040$(B = 256)이다. σ = 0.01 이면 한 스텝 기준으로 노이즈가 신호보다 크다.
- **반복 노출로 보호가 약해진다.** 같은 환자의 g가 에폭마다 한 번씩, 100 번 공개된다. 평균을 내면 노이즈는 1/√100 로 줄어든다. 따라서 "라벨 평문 유출 없음"은 단일 공개에 대한 주장으로 한정하고, 전체 학습에 대한 (ε, δ)는 합성(composition)을 고려해 산정해야 한다고 적는다. 아직 산정하지 않았다면 남은 과제로 둔다.

Algorithm 1은 다음과 같이 바꾼다.

```
for epoch = 1..E:
  for each mini-batch:
    for i = 1..K in parallel:
      s_i ← X_i w_i (+ b if i = 1)                  ▷ local, plaintext
      n_i ~ N(0, σ_DP² / K · I)                      ▷ local, never revealed
    y_B ← batch labels at P2                         ▷ P2 only
    (L, g) ← SPU(Σ s_i → clip → σ̃ → (σ̃ − y)/B)
    g̃ ← SPU(g + Σ n_i)                               ▷ noise added before reveal
    for i = 1..K in parallel:
      w_i ← Adam(w_i, X_iᵀ reveal_to_P_i(g̃))         ▷ local update
    (L is not revealed unless debugging)
```

2.3 라벨 입력과 설계 목표 (Sect. 5.2, 6.2, Table 6)

원고는 라벨을 "랜덤 덧셈 share로 분할하여 넣는다"고 쓰고, Table 6의 라벨 행에 "평문으로 보는 주체: 없음"이라고 적었다. 실제로는 P2가 라벨 원본을 가지고 SPU에 입력한다. 원고 6.4의 '라벨 입력 가

정' 단락이 이미 이 점을 인정하고 있으므로, 앞쪽 서술을 그에 맞춘다.

> 5.2 (ii) 대체안: 라벨 y는 이를 산출한 P2(PSG 기관) 외의 기관에 학습 중 평문으로 노출되지 않는다.
>
> 6.2 단계 2 대체안: P2는 배치 라벨을 SPU에 입력하며, 입력 시점에 ABY3 share로 분할되어 P1·P3는 무작위 share만 받는다.

2.4 데이터와 특성 (Sect. 6.1, 7.1, Table 5)

- 특성 수를 15 개에서 14 개로 바꾸고, 3.3 의 "$w_i \in R^5$"를 "$w_i \in R^{d_i}$, $(d_1, d_2, d_3) = (5, 4, 5)$"로 고친다. Table 2 의 w_i 설명도 함께 고친다.
- Table 5 의 P2 행을 "총 수면시간(slpprdp), 수면 효율(slpeffp), 깊은 수면 비율(times34p), WASO"로 바꾸고, sleep latency 를 뺀 이유를 한 문장 덧붙인다(피처 실험 결과 등).
- n = 1,266 → 5,356. 이벤트 XML 에서 desat 특성을 뽑을 수 있는 참가자로 한정한 inner join 이라는 점과 양성 비율 45.0%를 적는다.
- 병원별 CSV 는 같은 nsrrid 순서로 정렬되어 있고, 학습은 행 위치로 짝을 맞춘다. 2.1 절의 "환자 정렬은 사전에 완료" 가정과 일치하므로, 실제 운영에서는 PSI 가 필요하다는 문장을 덧붙인다.

2.5 실행 구조: 실제로 중앙 서버가 없음을 보이는 절 신설 (6 장)

원고는 '중앙 서버 없음'을 주장하지만 구현 근거를 쓰지 않았다. 현재 구현은 이를 직접 보여 주므로 6 장에 '6.x Deployment' 절을 추가한다.

- 세 기관이 각자 독립 프로세스에서 같은 프로그램을 실행한다(SecretFlow 프로덕션 모드, ray_mode=False). 조율하는 드라이버는 없다.
- 기관당 포트는 2 개이다. 하나는 SecretFlow 노드 간 객체 전달용(gRPC)이고, 다른 하나는 SPU 런타임 링크(brpc, ABY3 메시지 교환)용이다.
- 각 기관은 자기 CSV 만 읽고, 가중치와 Adam 상태도 자기 프로세스에만 둔다. 학습이 끝나면 각 기관이 자기 가중치만 저장한다.
- 배치 순서는 공개 시드에서 파생되어 세 기관이 통신 없이 같은 배치를 쓴다. 공개되는 것은 행 개수와 배치 인덱스이다.
- 실험은 한 머신의 루프백(127.0.0.1)에서 했다고 명시한다. 기관 간 실제 네트워크 지연은 반영되지 않았고, TLS 도 적용하지 않았다.

2.6 실험 설정과 결과 (Sect. 7.1, 7.2, Table 7)

원고의 빨간 '기재 필요' 자리에 다음 값을 넣는다.

항목	값
배치 크기 B / 에폭 E	256 / 100 (에폭당 16 배치, 마지막 불완전 배치는 버림)
옵티마이저	Adam, lr = 0.01, β = (0.9, 0.999), ε = 1e−8, 기관별 로컬
σ_DP	0.01 (기관별 조각 σ/√3, SPU 내부에서 합산)
분할	80/20 무작위 분할, random_state = 42, 학습 시드 0
SPU	SecretFlow 1.13.0b0, SPU 0.9.4, ABY3, FM128
하드웨어	WSL2 Ubuntu, 12 vCPU, 11 GB RAM, 3개 프로세스가 같은 머신에서 실행
학습 시간	100 에폭 624–644 s (약 6.3 s/에폭)

Table 7은 같은 분할(test 1,072명)로 다시 만든다. 괄호는 부트스트랩 95% 구간(1,000회)이다. 판정 임계값은 0.5이다.

모델	Accuracy	AUC	Sensitivity	Specificity
평문 (scikit-learn, BCE)	0.897 (0.88–0.91)	0.965 (0.96–0.97)	0.865 (0.83–0.89)	0.923 (0.90–0.94)
SPU, BCE형 + clip + DP(SPU 내부)	0.891 (0.87–0.91)	0.960 (0.95–0.97)	0.854 (0.82–0.89)	0.919 (0.89–0.94)

- 정확도 차이 0.6%p, AUC 차이 0.005 이고 구간이 겹친다. 같은 테스트 표본에서 두 모델의 예측 클래스는 97.5% 일치한다. 원고의 "6.2%p 손실"을 모두 이 수치로 바꾼다(Abstract, 기여 2, 7.2, 8, Table 9).
- 7.2 의 원인 분해 문단은 아래 ablation 표로 대체한다. 원고가 '아직 수행하지 않았다'고 적은 부분이다.

학습 방식 (SPU, 같은 분할)	최종 test acc	비고
MSE 자동미분 (원고 식 3), 공개 후 노이즈	0.825 (20 에폭)	100 에폭 재실행 필요 — 그대로는 비교 불가
$\sigma^{\frown}$하한 (bce_safe, clip 없음), 공개 후 노이즈	0.719	50 에폭 0.833 이후 발산
BCE형 + clip, 공개 후 노이즈 (σ = 0.01)	0.884	40 에폭 이후 0.88–0.90
BCE형 + clip, SPU 내부 노이즈 (σ = 0.01)	0.891	최종 모델

읽는 법: 성능 차이의 대부분은 그래디언트 형태(MSE·$\sigma^{\frown}$ vs BCE형 + clip)에서 나온다. 노이즈 위치를 공개 후에서 SPU 내부로 옮겨도 정확도는 거의 변하지 않았다(모든 행 σ = 0.01). 노이즈가 전혀 없는 실행은 하지 않았다. 다만 각 설정을 시드 하나로 한 번씩만 학습했으므로, 시드 3–5개의 평균 ± 표준편차로 바꾸는 것을 권한다.

2.7 실험 위생: 원고에 적거나 고칠 것

- **표준화 누수:** 현재 각 기관이 test 를 포함한 전체 행으로 평균과 표준편차를 계산한다. train 행으로만 fit 하도록 고치거나, 그대로 둘 거면 적어 둔다.
- **설정 선택에 test 를 씀:** 손실 변형과 에폭 수를 test_acc 를 보며 골랐다. 검증셋(train 의 10%)을 떼어 선택하고, test 는 마지막에 한 번만 보도록 바꾼다.
- **체크포인트:** 최고 에폭이 아닌 마지막(100) 에폭 가중치를 쓴다고 명시한다. 에폭 선택에 따른 누수는 없다.
- **임계값:** train 에서 Youden 지수로 고르면 0.39 이다. test 에서 민감도 0.905, 특이도 0.868, 정확도 0.884 이다. 선별 용도의 임계값으로 7 장에 짧게 넣는다. 0.5 결과와 함께 보고한다.

2.8 평문 노출 분석 (Sect. 6.4, Table 6)

'의도적으로 공개되는 평문 중간값은 L과 g 두 가지'를 다음으로 바꾼다.

> 학습 중 소유자 외 주체에게 평문으로 공개되는 값은 (a) SPU 내부에서 DP 노이즈가 더해진 그래디언트 $\tilde{g}$, (b) 평가 시점의 테스트 정확도 스칼라, (c) 공개 메타데이터(표본 수, 공개 시드로 정해지는 배치 인덱스)뿐이다. 손실 L은 계산되지만 공개되지 않는다.

Table 6에서 바꿀 행은 다음과 같다.

단계	값	평문으로 보는 주체	그 외 주체가 받는 형태
학습	라벨 y	P2 (원본 보유)	SPU 덧셈 share
학습	배치 손실 L	없음 (기본)	SPU 내부 share
학습	그래디언트	각 기관 ($\tilde{g} = g + \Sigma n_i$)	공개 전 SPU 내부에서 노이즈 합산
학습 (신규)	테스트 정확도	모든 기관	스칼라 1개 공개
학습 (신규)	표본 수, 배치 인덱스	모든 기관	공개 메타데이터
추론 (신규)	표준화 평균·표준편차	클라이언트	모델 파일로 배포 (집계 통계)

3. 추론 파트 수정

3.1 구현 기반 명시 (Sect. 3.2, 6.3, 7.3)

- CKKS 라이브러리를 HEaaN2 로 명시하고, 7.3 과 Table 8 에 CKKS 파라미터(N, 모듈러스, scale, 보안 수준)를 적는다.
- 학습 결과는 기관별 체크포인트(가중치, 표준화 값)에서 HEAAN2_LINEAR_V1 텍스트 모델로 내보낸다. 내보낸 파일만으로 평문 추론을 다시 해 보면 test 정확도 0.8909 로 학습 로그와 일치한다. 이 문장을 7.3 에 넣으면 '평문 추론' 열의 근거가 된다.

- Table 8 의 평문 열을 0.832 / 0.921 에서 **0.891 / 0.960** 으로 바꾼다. '요청 크기' 행도 15 개 실수에서 14 개 실수로 고친다.

3.2 합산 주체: Peers → Client (Alg. 2, Sect. 6.3)

Algorithm 2의 5행 "Peers: ct(z) ← Add(...)"는 누가 합산하는지 모호하다. 병원 간 통신이 필요한 것처럼 읽히기도 한다. 클라이언트가 합산하면 추론 단계에서 병원 간 통신이 없어지고 구조도 단순해진다.

```
1: Client: for i = 1..K: ct_i ← Enc(standardize(x_i), pk_cl); send ct_i to P_i
2: P_i:    ct(s_i) ← cMul(ct_i, w_i) and Add (+ b at P1); return ct(s_i)
3: Client: ct(z) ← Add(ct(s_1), …, ct(s_K))        ▷ no ct-ct mult., no hospital-to-hospital
traffic
4: Client: z ← Dec(ct(z), sk_cl); ŷ ← σ(z); label ← [ŷ ≥ τ]
```

- **복호화는 합산 뒤 한 번만** 한다. s_i 를 각각 복호화하면 클라이언트가 기관별 기여를 보게 되어 가중치 추출이 쉬워진다. 6.4 '추론 결과' 단락에 이 이유를 적는다.
- 병원은 자기 가중치 행만 받는다(모델 파일 전체가 아님). 클라이언트는 특성 이름, 인덱스, 표준화 값만 받는다.
- 키는 클라이언트가 pk 와, slot packing 을 쓸 경우 Galois(rotation) 키를 병원에 보낸다. 3.2 의 "pk 만 공개"를 "pk 와 (필요 시) Galois 키"로 고친다.

3.3 측정 항목 (Table 8)

- 아직 측정 전인 항목은 그대로 두되 인코딩 방식(slot packing / 특성별 암호문 / 계수 packing)을 먼저 정해 7.3 에 적는다. 측정값이 모두 이 선택에 달려 있다.
- 학습 비용도 Table 8 과 같은 수준으로 보고하면 좋다: 에폭당 시간, 배치당 SPU 호출 시간, 기관 간 송수신 바이트.

4. 논문 구성 검토

4.1 유사 논문의 일반적인 흐름

프라이버시 보존 VFL·MPC/HE 학습 논문(예: Falcon, Yang et al. 2019b, AegisFL)은 세부 이름은 달라도 대체로 아래 순서를 따른다. 원고와 대응시키면 다음과 같다.

일반적인 장	역할	원고의 대응
Introduction	문제, 기존 방식의 한계, 기여	1장 — 충실함
Related Work	VFL·라벨 유출 방어·MPC/HE ML·응용 분야 연구 비교	없음. 2장 Background가 일부, 7.4가 응용 분야 일부를 대신함
Preliminaries	비밀분산, HE, DP 정의	3장. DP 정의가 없음
Problem Statement	시스템 모델, 위협 모델, 설계 목표	5장. 4장(모델 선택)보다 뒤에 있음

일반적인 장	역할	원고의 대응
System Design	개요 그림, 학습, 추론, 모델 수정	6장 + 4장이 나뉘어 있음
Security / Privacy Analysis	보장 성질, 공개 값, DP 산정	6.4가 설계 장 안에 들어 있음
Experiments	설정, 정확도, ablation, 효율, 확장성	7장. ablation과 학습 비용 없음, 7.4·7.5는 실험이 아님
Discussion / Limitations	가정, 한계, 적용 범위	7.5와 8장 '남은 과제'에 흩어져 있음
Conclusion	요약	8장

4.2 현재 구성의 문제

1. **Related Work 가 없다.** 심사자가 가장 먼저 찾는 장이다. Table 1(방식 비교)과 Table 9(응용 연구 비교)가 그 역할을 일부 하지만, 라벨 유출 방어(DP·노이즈 기반) 연구와 MPC 프레임워크 비교가 빠져 있다.
2. **모델 선택(4 장)이 문제 정의(5 장)보다 앞에 있다.** 위협 모델과 설계 목표를 먼저 세워야 '왜 로지스틱 회귀인가'가 그 목표(통신 라운드, 곱셈 깊이)에 대한 답으로 읽힌다.
3. **보안 분석이 설계 장 안에 있다.** 논문의 첫 번째 기여가 '평문 노출 분석'인데 6.4 라는 소절이다. 독립된 장으로 올리고, 명제(Proposition) 형태로 쓰면 기여가 분명해진다. DP 산정도 이 장에 들어간다.
4. **7 장에 실험이 아닌 절이 섞여 있다.** 7.4(선행 연구 수치 비교)는 '직접 비교할 수 없다'는 결론이므로 Related Work 나 Discussion 에 맞다. 7.5(웨어러블 현실성)는 측정이 없는 논의이므로 Discussion 에 맞다.
5. **실험이 정확도 한 표뿐이다.** ablation, 학습 비용, 시드 반복, 임계값별 성능이 없다. Table 3(후보 모델 비교)도 수치 없이 '향상 미미'로만 적혀 있다. README 에 있는 수치(로지스틱 회귀 0.891/0.960, MLP 0.895/0.960 등)를 넣는다.
6. **Preliminaries 에 DP 가 없다.** DP 를 핵심 방어 수단으로 쓰면서 (ε, δ) 정의와 가우시안 메커니즘이 없다.

4.3 제안 목차

```
1. Introduction            (현행 유지, 수치·기여 갱신)
2. Related Work            (신설)
   2.1 VFL과 제3자 없는 로지스틱 회귀       ← 현 Table 1 이동
   2.2 라벨·특성 추론 공격과 방어(DP 등)    ← 현 2.2 확장
   2.3 MPC/HE 기반 학습·추론 프레임워크
   2.4 수면무호흡증 예측과 웨어러블 입력     ← 현 7.4, Table 9 이동
3. Preliminaries           (현 3장 + 3.4 Differential Privacy)
4. Problem Formulation     (현 5장: 시스템 모델, 위협 모델, 설계 목표)
5. System Design
   5.1 Overview (Figure 1 갱신)   5.2 Model Choice & Modifications ← 현 4장
```

```
   5.3 Secure Training           5.4 Encrypted Inference
   5.5 Deployment (기관당 2포트, 중앙 드라이버 없음)
6. Privacy Analysis        (현 6.4 승격: 명제, Table 6, DP 산정)
7. Experiments
   7.1 Setup   7.2 Accuracy vs Plaintext   7.3 Ablation
   7.4 Training Cost   7.5 Inference Overhead (Table 8)   7.6 Threshold
8. Discussion & Limitations (현 7.5 + 정렬·honest-majority·PSG 특성 한계)
9. Conclusion
```

4.4 그 밖의 수정

- **Figure 1:** P2 특성 4 개, 라벨 입력 화살표를 P2 → SPU 로, 노이즈 조각 입력 화살표 추가, '공개: L' 제거, 'g + DP 노이즈'를 'g̃(노이즈는 SPU 내부)'로 바꾼다.
- **Abstract:** 세 번째 문장의 "손실을 MSE 로 바꿨으며"를 "BCE 형 그래디언트와 logit clip 으로 log·exp 를 피했으며"로 바꾸고, 수치를 0.891 / 0.960 으로 갱신한다.
- **기여 목록:** 원고에서 미완이던 항목(노이즈 위치, ablation)이 완료되었으므로 '학습의 보안성–정확도 균형' 항목에 'SPU 내부 DP 적용 후에도 평문 대비 0.6%p'를 넣는다.
- **Table 9 'Ours' 행:** n = 5,356, 14 개 특성, 정확도 89.1%, AUC 0.960.
- **Impact Statement:** 노이즈 위치 문장을 지우고 'σ_DP = 0.01 에 대한 (ε, δ) 산정은 남은 과제'로 바꾼다.

5. 남은 작업 체크리스트

작업	목적	규모
MSE 자동미분 변형을 100 에폭으로 재실행	ablation 표를 공정하게	실행 1회 (약 11분)
시드 3–5개로 반복	평균 ± 표준편차 보고	설정당 실행 3–5회
검증셋 분리, 표준화를 train으로만 fit	test 누수 제거	코드 수정 소량 + 재학습
σ_DP = 0.01, E = 100, B = 256에 대한 (ε, δ) 산정	DP 주장의 근거	계산과 서술
CKKS 인코딩 결정과 Table 8 측정	추론 오버헤드 보고	HEaaN2 구현 후 측정
PSI 단계 (또는 정렬 가정 명시)	실제 배포 가정 정리	서술 또는 구현
Related Work 장 작성	구성 보완	서술