중앙 서버 없는 프라이버시 보존 수직 연합학습 기반 수면무호흡증 예측

김호영, 이지향

Abstract

수면무호흡증 예측에 필요한 데이터는 여러 의료기관에 수직으로 분할되어 있고, 개인정보 보호 규제 때문에 원본을 한 곳에 모으기 어렵다. 또한 정확도가 높은 기존 연구는 밤 전체 단일 리드 ECG 원신호를 입력으로 쓰지만, 스마트워치의 ECG는 사용자가 버튼에 손가락을 대고 30초간 측정하는 방식이어서 수면 중 연속 신호를 얻기 어렵다. 본 논문은 SpO2·심박·수면 구조의 밤 전체 요약 통계를 입력으로, 중앙 서버 없이 3개 병원이 공동 학습하고 외부 클라이언트에 암호화 추론을 제공하는 수직 연합학습(VFL) 시스템을 제안한다. 본 논문은 세 가지를 보인다. 첫째, 학습(SecretFlow SPU, ABY3)과 추론(클라이언트 키 CKKS) 전 과정에서 원시 특성, 결합 logit, 손실, 추론 입력·출력은 소유자 외의 주체에게 평문으로 노출되지 않고, 라벨은 이를 산출한 기관 밖으로 평문 노출되지 않는다. 기관에 공개되는 학습 중간값은 SPU 내부에서 Gaussian 노이즈를 더한 그래디언트 하나이며, 이에 대한 라벨 차분 프라이버시 예산을 산정한다. 둘째, 세 기관이 독립 프로세스로 실행되는 SPU 학습 모델은 SHHS1 5,356명에서 정확도 0.891, AUC 0.960으로, 같은 분할의 평문 통합 학습(0.897, 0.965)과 정확도 0.6%p 차이에 그쳤다. 셋째, 학습 시 시그모이드를 구간 제한(clip)한 3차 다항식으로 근사하고 BCE 형태의 그래디언트를 직접 지정해 MPC에서 log·exp 연산을 없앴으며, 추론 시에는 시그모이드를 암호문 경로에서 빼서 병원 측 연산을 평문 가중치와 암호문 내적만으로 구성했다.

데이터를 한곳에 모아 암호 없이 학습한 모델(0.897)과 비교해, 데이터를 각 병원에 둔 채 비밀분산으로 학습한 모델(0.891)이 정확도 0.6%p 차이밖에 나지 않았다.

1. Introduction

수면무호흡증 예측은 산소포화도, 심박수, 수면 구조 지표, 인구통계 정보 등 여러 종류의 신호를 함께 고려해야 하는 문제이다. 이 데이터는 병원별로 서로 다른 검사 항목을 통해 수집되므로, 같은 환자에 대해 기관마다 다른 특성(feature) 열을 갖는 수직 분할(vertical partition) 형태로 존재하는 경우가 많다. 환자 개인정보 보호 규제와 기관 간 데이터 공유에 대한 소극적 태도 때문에 원본을 한곳에 모으기도 어렵다.

수직 연합학습(VFL)은 각 기관이 원본 특성을 공유하지 않고 모델을 공동 학습하게 해 준다. 그러나 이를 의료 환경에 그대로 적용하면 다음 네 가지 문제가 생긴다.

첫째, 중앙 서버(코디네이터)에 대한 신뢰. 다수의 기존 VFL 연구는 중간 연산 결과를 집계하거나 복호화하는 제3자를 전제한다 (Hardy et al., 2017). 모두가 신뢰할 수 있는 제3자를 찾기 어렵고 제3자 참여 자체가 유출 위험을 키운다 (Yang et al., 2019b). 데이터 주권에 민감한 병원은 암호화된 형태라 하더라도 자기 데이터 관련 연산이 외부 서버를 거치는 구조를 기피할 수 있다.

둘째, 라벨 유출. 로지스틱 회귀의 그래디언트는 잔차 $(\hat{y} - y)$의 선형 결합이며, $\hat{y} \in (0, 1)$이므로 잔차의 부호만으로 라벨이 드러난다. 라벨(수면무호흡 여부)은 그 자체로 민감한 진단 정보이다. 노이즈를 더하더라도 노이즈 없는 그래디언트를 먼저 보는 주체가 있으면 보호가 성립하지 않는다.

셋째, 모델 복잡도와 암호 연산 비용. 비선형 은닉층이 많은 모델은 MPC에서는 통신 라운드를, 동형암호(HE)에서는 곱셈 깊이를 소모한다. Falcon (Wu et al., 2023)은 MLP 학습이 로지스틱 회귀보다 훨씬 느리며, 시그모이드 같은 비선형 함수의 보안 연산이 비용이 크다고 보고했다.

넷째, 웨어러블에서 얻을 수 있는 입력. ECG 원신호를 CNN에 넣는 연구는 PhysioNet Apnea-ECG에서 기록 단위 정확도 97.1%를 보고했지만, 그 입력은 100 Hz로 401–587분 동안 연속 기록한 단일 리드 ECG이다 (Wang et al., 2019). Galaxy Watch의 ECG 앱은 30초 정지 측정 방식이므로 수면 중 연속 ECG를 얻는 용도가 아니며 (Samsung Electronics), FDA De Novo 허가를 받은 Samsung 수면무호흡 기능도 PPG에서 유도한 SpO2로 판정한다 (U.S. FDA, DEN230041).

본 논문은 이 네 문제를 함께 다루는 완전 분산(peer-to-peer) 시스템을 제안한다. 핵심 관찰은 로지스틱 회귀의 logit이 특성 블록에 대해 선형이라는 점이다. 각 병원이 자기 특성과 가중치로 계산한 로컬 logit s_i가 그대로 결합 logit z의 덧셈 항이 되므로, 원시 특성은 기관 밖으로 나가지 않고 비선형 연산(시그모이드, 그래디언트, 노이즈 합산)만 MPC 내부에서 수행하면 된다. 추론 시에는 은닉층과 활성화 함수가 없어 암호문 간 곱셈이 필요 없다. 본 논문의 기여는 다음과 같다.

- **평문 노출 분석과 라벨 DP:** 학습·추론 각 단계에서 어떤 값이 누구에게 평문으로 보이는지 전수 정리한다(Sect. 6, Table 7). 그래디언트에는 SPU 내부에서 노이즈를 더한 뒤 공개하고, 반복 공개에 대한 라벨 (ε, δ)-DP 예산을 zCDP 합성으로 산정한다.
- **보안성–정확도 균형:** SPU 학습이 평문 통합 학습 대비 정확도 0.6%p, AUC 0.005 차이로 동작하며, 이전 구현의 6%p 손실이 주로 그래디언트 형태에서 왔음을 ablation 으로 보인다(Sect. 7.2–7.3).
- **완전 분산 구현:** 세 기관이 독립 프로세스에서 같은 프로그램을 실행하고 중앙 드라이버 없이 기관당 두 개의 포트로만 통신하는 배포 구조를 제시한다(Sect. 5.5).
- **로지스틱 회귀 수정과 추론 경로:** 표준 로지스틱 회귀에서 바꾼 부분을 정리하고(Table 5), 클라이언트가 암호문 상태로 합산하는 CKKS 추론과 그 측정 항목을 제시한다(Sect. 5.4, 7.5).

추론 시 동형암호를 사용했을 때와 평문을 사용했을 때 비교

2. Related Work

2.1. 제3자 없는 수직 로지스틱 회귀

Hardy et al. (2017)은 Paillier 가법 동형암호로 수직 로지스틱 회귀를 학습하지만 양측이 신뢰하는 코디네이터를 둔다. Yang et al. (2019b)는 코디네이터를 제거했으나 라벨은 단일 참여자가 보유하며 잔차를 통한 라벨 복원 가능성을 보안 분석에서 밝혔다. Falcon (Wu et al., 2023)은 threshold Paillier와 가법 비밀분산을 결합해 데이터를 열람하지 않는 스케줄러만 남겼다. 본 연구는 학습의 비선형 부분 전체를 3자 MPC로 옮기고, 추론을 클라이언트 키 CKKS로 분리한다(Table 1).

Table 1. 기존 VFL 로지스틱 회귀 방식과의 비교. 기존 방식의 항목은 각 원문 기술에 근거함.

Schemes	프라이버시 기술	제3자 코디네이터	라벨 처리	추론 보호
Hardy et al. (2017)	Paillier (가법 HE)	있음 (신뢰 필요)	단일 참여자	해당 없음
Yang et al. (2019b)	Paillier (가법 HE)	없음	단일 참여자 (party A)	해당 없음
Falcon (Wu et al., 2023)	Threshold Paillier + 가법 비밀분산	스케줄링 전용 (데이터 비열람)	단일 참여자 (active party)	PHE + SSS
Ours	SPU MPC (ABY3) + CKKS + SPU 내부 DP	없음	산출 기관만 보유, 학습 중 share로만 사용	클라이언트 키 CKKS

2.2. 추론 공격과 방어

VFL에서 교환되는 중간 결과는 원본이 아니더라도 추론 공격의 단서가 된다. 수동 참여자가 그래디언트나 잔차로부터 라벨을 추정하는 라벨 추론 공격 (Fu et al., 2022; Li et al., 2022)과, 예측값이나 로컬 logit으로부터 다른 참여자의 특성을 추정하는 특성 추론 공격 (Luo et al., 2021)이 대표적이다. 방어로는 공개 값에 무작위 노이즈를 더하는 방법이 널리 쓰이며 (Li et al., 2022), 그 보장은 차분 프라이버시 (Dwork & Roth, 2014)로 정량화된다. 학습 과정의 반복 공개에 대한 누적 예산은 합성 정리로 산정한다 (Abadi et al., 2016; Bun & Steinke, 2016). 본 연구는 보호 대상이 라벨이므로 라벨 DP (Ghazi et al., 2021)로 분석한다.

2.3. MPC·HE 기반 학습과 추론

SecretFlow-SPU (Ma et al., 2023)는 JAX로 작성한 계산을 MPC 프로토콜로 컴파일해, 평문과 같은 형태의 코드로 비밀분산 연산을 수행하게 한다. 본 구현은 그중 3자 honest-majority 프로토콜인 ABY3 (Mohassel & Rindal, 2018)를 쓴다. 추론에는 근사 산술 동형암호 CKKS (Cheon et al., 2017)를 쓰며, AegisFL (Chen et al., 2024)은 CKKS 내적에서 slot rotation이 지배적 비용임을 보이고 계수 packing으로 이를 제거했다.

2.4. 수면무호흡증 예측과 입력 신호

기존 수면무호흡증 예측 연구는 데이터셋, 판정 단위, 입력, 평가 지표가 본 연구와 달라 수치를 직접 비교할 수 없다(Table 2). ECG 기반 연구(97.1%)는 수면클리닉 70개 기록을 분 단위로 판정해 기록 단위로 집계하고, 비교 연구 대부분은 ECG나 SpO2 원신호 파형을 CNN에 넣는다. 본 연구는 40세 이상 성인 다기관 코호트인 SHHS1에서 환자 1명당 1행으로 AHI ≥ 15를 직접 분류하며, MPC·HE 비용을 로지스틱 회귀 수준으로 유지하기 위해 요약 통계를 쓴다. 같은 AHI 15 기준의 Samsung 결과(일치율 85.5%)와 판정 기준이 가장 가깝지만 대상 집단과 입력이 달라 참고 수치로만 제시한다.

Table 2. 기존 연구의 보고 성능. FDA 요약서의 민감도·특이도 사례 수(167/202, 235/268)로 계산한 전체 일치율은 402/470 = 85.5%이다.

연구	데이터	입력	판정	보고 성능
Wang et al. (2019), modified LeNet-5	PhysioNet Apnea-ECG (70 기록)	단일 리드 ECG	기록 단위, AHI 기준	정확도 97.1% (LR 기준선 88.6%)
Chang et al. (2020), 1D CNN	PhysioNet Apnea-ECG (70 기록)	단일 리드 ECG	기록 단위	정확도 97.1%
Mortazavi et al. (2024)	CHAT (소아)	SpO2 원신호	AHI 추정 후 5 e/h 임계	정확도 91.24% (fold-2)
OxiNet (Levy et al., 2023)	SHHS1/SHHS2 외	SpO2 원신호	4단계 중증도	macro-F1 0.84 / 0.83
KindSleep (Nnamdi et al., 2026)	SHHS, CFS, MrOS (n = 9,815)	SpO2 + 임상 정보	중증도 분류	weighted F1 0.827–0.941
DRIVEN (Retamales et al., 2024)	NSRR 3개 연구 (14,370 기록)	센서 2종	4단계 AHI 분류	정확도 72.4%
Samsung Sleep Apnea Feature (U.S. FDA, DEN230041)	다기관 임상, 470명 평가	워치 PPG 유래 SpO2	AHI 15, 2박	민감도 82.7%, 특이도 87.7%
Ours (SPU MPC)	SHHS1 (n = 5,356)	밤 전체 요약 통계 14개	환자 단위, AHI ≥ 15	정확도 89.1%, AUC 0.960

3. Preliminaries

3.1. Secret Sharing and SecretFlow SPU

학습 단계의 비선형 연산은 SecretFlow의 SPU 백엔드에서 수행한다 (Ma et al., 2023). ABY3에서 값 v는 세 참여자에게 복제(replicated) 비밀분산되어 각 참여자가 세 조각 중 두 개를 가지며, 단일 참여자가 보는 조각은 균일 무작위이다. 덧셈은 통신 없이, 곱셈은 1라운드 통신으로 계산되고 비교 연산도 지원된다. 평문 값이 SPU에 입력되는 시점(.to(spu))이 평문과 share의 경계이며, SPU 밖으로는 명시적으로 공개(reveal)한 값만 나온다. 특정 기관에게만 공개(reveal_to_P_i)하는 것도 가능하다.

3.2. RLWE-based Homomorphic Encryption (CKKS)

추론 단계에서는 CKKS (Cheon et al., 2017)를 사용하며 구현에는 HEaaN2 라이브러리를 쓴다. 사용하는 연산은 다음과 같다.

- **KeyGen.** 클라이언트가 (pk_{cl}, sk_{cl})을 생성하고 pk_{cl}과, slot 합산이 필요한 경우 Galois 키를 병원에 공개한다. sk_{cl}은 클라이언트 밖으로 나가지 않는다.
- **Enc / Dec.** 클라이언트가 자신의 특성 벡터를 암호화하고, 결과 암호문을 복호화한다.
- **Add(ct, ct′).** 암호문 간 덧셈. 곱셈 깊이를 소모하지 않는다.
- **cMul(ct, w).** 평문 가중치 w 와 암호문의 곱. relinearization 이 필요 없고 rescale 로 레벨 1 개를 사용한다.

3.3. Differential Privacy

메커니즘 M이 한 표본만 다른 인접 데이터셋 D, D′에 대해 $\Pr[M(D) \in S] \le e^{\varepsilon} \Pr[M(D') \in S] + \delta$를 만족하면 (ε, δ)-DP이다 (Dwork & Roth, 2014). 본 논문은 인접 관계를 한 표본의 라벨만 다른 경우로 정의하는 라벨 DP (Ghazi et al., 2021)를 쓴다. L2 민감도 Δ인 함수에 $N(0, \sigma^2 I)$를 더하는 Gaussian 메커니즘은 $\rho = \Delta^2/(2\sigma^2)$의 ρ-zCDP를 만족하고, zCDP는 합성 시 ρ가 더해지며, ρ-zCDP는 임의의 $\delta > 0$에 대해 $(\rho + 2\sqrt{(\rho \ln(1/\delta))}, \delta)$-DP이다 (Bun & Steinke, 2016).

3.4. Vertically Partitioned Logistic Regression

기관 i는 가중치 $w_i \in \mathbb{R}^{d_i}$, $(d_1, d_2, d_3) = (5, 4, 5)$를 보유하며, 편향 b는 P_1만 보유한다. 로컬 logit과 결합 logit은 다음과 같다.

$$s_i = w_i^{T} x_i \ (+b \text{ if } i = 1), \quad z = \Sigma_i s_i, \quad \hat{y} = \sigma(z). \tag{1}$$

logit이 특성 블록에 대해 선형이므로 각 기관이 로컬에서 계산한 s_i는 그 자체로 z의 덧셈 항이 된다. MPC 내부에서 시그모이드는 다음 3차 다항식으로 근사하고, 그 입력은 단조 증가 구간으로 제한한다.

$$\tilde{\sigma}(z) = 0.5 + 0.197z - 0.004z^3, \quad \hat{z} = \mathrm{clip}(z, -4, 4). \tag{2}$$

결합 logit에 대한 그래디언트는 손실을 자동 미분하지 않고 BCE의 그래디언트 $(\sigma(z) - y)/B$에서 σ를 $\tilde{\sigma} \circ \mathrm{clip}$으로 바꾼 형태로 직접 지정한다(Appendix C).

$$g^{(n)} = (\tilde{\sigma}(\hat{z}^{(n)}) - y^{(n)}) / B, \quad L = (1/B) \Sigma_n (\tilde{\sigma}(\hat{z}^{(n)}) - y^{(n)})^2. \tag{3}$$

L은 SPU 내부에서만 계산되는 모니터링 값이며 g의 원함수가 아니다. 사용한 기호는 Table 3에 정리했다.

Table 3. Notations.

기호	설명
K	참여 기관 수 (K = 3)
P_i	i번째 기관 (병원 노드)
x_i, X_i	기관 i의 특성 블록 (표본 1개 / 배치)
w_i, b	기관 i의 가중치 ($\mathbb{R}^{d_i}$), P_1의 편향
s_i	기관 i의 로컬 logit (z의 덧셈 항)
z, $\hat{z}$, $\hat{y}$	결합 logit, clip된 logit, 예측 확률
$\tilde{\sigma}$	3차 다항식 시그모이드 근사
g, $\tilde{g}$	결합 logit 그래디언트, 노이즈가 더해진 공개 그래디언트
n_i	기관 i가 생성한 노이즈 조각 $N(0, \sigma_{DP}^2/K)$
B, E	배치 크기, 에폭 수
σ_{DP}	합산 노이즈 표준편차
pk_{cl}, sk_{cl}	추론 클라이언트의 CKKS 공개키·비밀키

4. Problem Formulation

4.1. System Model

시스템은 3개 병원 노드 P_1, P_2, P_3와 추론을 요청하는 외부 클라이언트로 구성되며, 중앙 서버나 키 센터는 없다. P_2는 수면다원검사(PSG)를 수행하는 기관으로 AHI에서 유도한 라벨의 원본을 보유한다. 세 기관은 동일한 환자 집합에 대해 특성 블록 $x = [x_1; x_2; x_3]$을 나누어 가지며, 기관 간 환자 정렬은 사전에 완료되었다고 가정한다. 이는 Falcon 등 기존 VFL 연구와 같은 가정이다.

4.2. Adversarial Model

- **병원 노드:** semi-honest 로 가정한다. 프로토콜은 정직하게 따르되 수신한 메시지로부터 다른 기관의 특성·라벨을 추론하려 할 수 있다. ABY3 는 honest-majority 가정이므로 세 기관 중 최대 1 개가 오염된 경우를 다루며, 두 기관의 공모는 범위 밖이다.
- **추론 클라이언트:** 자신의 CKKS 비밀키를 보유하며 semi-honest 로 가정한다. 병원은 클라이언트 비밀키에 접근하지 않는다.
- **범위 밖:** 악의적 참여자, 공개된 모델 출력에 대한 반복 질의 공격, 기관 간 환자 정렬 과정의 프라이버시.

4.3. Design Goals

- **Privacy.** (i) 원시 특성은 각 기관 밖으로 나가지 않는다. (ii) 라벨 y 는 P_2 외의 기관에 평문으로 노출되지 않는다. (iii) 결합 logit z 와 손실 L 은 학습 중 평문으로 복원되지 않는다. (iv) 공개되는 그래디언트의 라벨 정보는 DP 예산으로 정량화한다. (v) 추론 요청의 특성과 결과는 병원에 평문으로 노출되지 않는다.
- **Decentralization.** 중앙 서버나 조율 드라이버 없이 병원 노드 간 직접 통신으로 동작하며, 병원 간 비밀키 공유가 없다.
- **Efficiency.** 학습의 MPC 통신 라운드와 추론의 CKKS 곱셈 깊이를 최소화한다.
- **Accuracy.** 평문 통합 학습과 비교 가능한 수준의 예측 성능을 유지한다.

5. System Design

5.1. Overview

시스템은 데이터 분할, MPC 학습, CKKS 추론의 세 단계로 구성된다. 학습은 로컬 logit → (SPU) 합산·clip·시그모이드·그래디언트·노이즈 합산 → 로컬 역전파 순서로, 추론은 암호문 logit 계산 → 클라이언트 측 암호문 합산 → 복호화 순서로 진행된다(Figure 1).

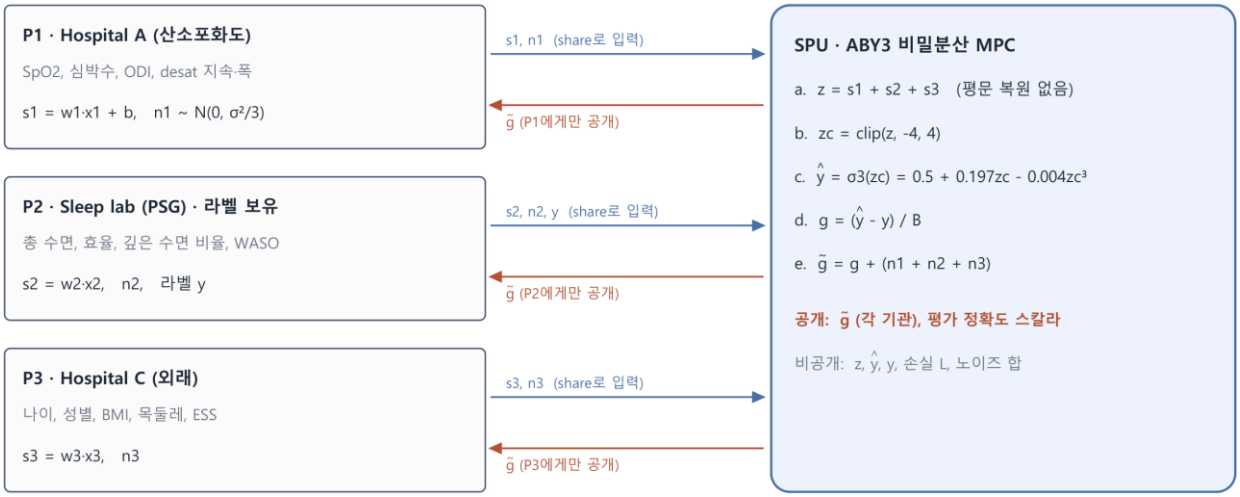


Figure 1. 학습 단계 시스템 모델(3개 병원 + SPU, 중앙 서버 없음). 각 병원은 로컬 logit s_i와 노이즈 조각 n_i를 SPU에 share로 넣고, 라벨은 P_2만 입력한다. SPU는 노이즈를 더한 $\tilde{g}$만 각 병원에 따로 공개한다. 그림의 σ3는 식 (2)의 $\tilde{\sigma}$이다. x_i, w_i와 가중치 갱신(Adam, $X_i^T\tilde{g}$)은 각 병원 안에만 있다.

5.2. Model Choice and Modifications

후보 모델을 비교한 결과, 로지스틱 회귀가 MPC 통신 라운드와 CKKS 곱셈 깊이를 모두 최소화하면서 성능 손실이 없는 선택이었다(Table 4). 적합한 이유는 세 가지이다.

(1) Block-linearity로 MPC 입력이 단순해진다. 식 (1)에서 $z = \Sigma_i s_i$이므로 각 기관은 원시 특성 대신 스칼라 s_i 하나만 share로 입력한다. MPC 내부 연산은 덧셈 → clip → 3차 다항식 → 그래디언트로 끝나며 은닉층의 행렬곱이 없다.

(2) 추론에서 암호문 간 곱셈이 필요 없다. 추론은 평문 가중치와 암호화된 특성의 내적(cMul + Add)뿐이며, 시그모이드는 클라이언트가 복호화한 z에 평문으로 적용한다.

(3) 더 복잡한 모델의 이득이 없었다. 은닉층·2차항 모델은 깊이만 늘리고 성능 향상이 표준편차 이내였다. 트리 모델은 분기마다 비교가 필요해 CKKS에서 비용이 크다.

Table 4. 후보 모델 비교 (평문, 이전 15특성 구성 n = 2,444, 5개 시드 평균). 깊이는 추론 시 암호문 간 곱셈 깊이.

Model	깊이	정확도	AUC
로지스틱 회귀	0	0.891	0.960
2차항 로지스틱 회귀	1	0.881	0.956
MLP (다항 활성화)	≥ 2	0.895	0.960
MLP + 비선형 top	≥ 2	0.891	0.960
HistGradientBoosting	비교 필요	0.893	0.963

표준 로지스틱 회귀를 그대로 MPC·HE에 올리면 학습에서는 exp와 log를, 추론에서는 시그모이드의 고차 근사를 암호 연산으로 계산해야 한다. 이를 피하기 위해 Table 5의 부분을 바꿨다.

Table 5. 표준 로지스틱 회귀 대비 수정 사항.

구성 요소	표준 로지스틱 회귀	본 시스템 · 학습 (SPU)	본 시스템 · 추론 (CKKS)	바꾼 이유
시그모이드	$\sigma(z) = 1/(1+e^{-z})$	$\tilde{\sigma}(\text{clip}(z,-4,4))$	암호문 경로에서 제거, 클라이언트가 복호화 후 평문 σ 적용	exp 회피, 단조 구간 보장, CKKS 깊이 회피
손실·그래디언트	BCE (log 포함), 자동 미분	BCE형 그래디언트 $(\tilde{\sigma}(\hat{z}) - y)/B$ 직접 지정, 손실은 비공개 모니터링	해당 없음	log 회피, $\tilde{\sigma}'$ 소실·부호 반전 방지
파라미터 보유	단일 w, b	기관별 w_i, b는 P_1만	학습과 동일, 병원 밖으로 나가지 않음	block-linearity
logit 계산	$z = w^Tx$ 한 곳에서	로컬 s_i 평문 → SPU에서 share 합산	병원별 $\text{Enc}(s_i)$ → 클라이언트가 암호문 덧셈	z를 평문으로 복원하지 않음
라벨	평문	P_2가 SPU에 입력, 다른 기관은 share만 받음	해당 없음	라벨 보유 기관 밖 노출 차단
가중치 갱신	중앙에서 $X^T(\hat{y} - y)$	SPU 내부에서 노이즈를 더한 $\tilde{g}$를 기관별 공개, Adam 로컬 갱신	해당 없음	X_i를 밖으로 내보내지 않음, 라벨 DP
모델 구조	은닉층·교호작용 항 선택 가능	선형 logit만	평문-암호문 곱과 덧셈만	Table 4의 비교 결과

다항식의 유효 범위와 clip. $\tilde{\sigma}'(z) = 0.197 - 0.012z^2$이므로 |z|가 약 4.05를 넘으면 $\tilde{\sigma}$는 단조성을 잃고, |z| > 약 7에서는 $\tilde{\sigma}'$가 음수가 되어 y = 1인 표본의 그래디언트가 z를 더 키우는 양의 되먹임이 생긴다. 본 시스템은 SPU 내부에서 z를 [−4, 4]로 제한해 $\tilde{\sigma}$를 항상 단조 증가 구간에서 계산한다. 이때 출력 범위는 $[\tilde{\sigma}(-4), \tilde{\sigma}(4)] \approx [-0.032, 1.032]$이다. clip은 ABY3의 비교 연산으로 계산된다.

학습과 추론의 판정 일치. $|\hat{z}| \le 4$에서 $0.197 - 0.004\hat{z}^2 \ge 0.133 > 0$이므로 $\tilde{\sigma}(\hat{z}) \ge 0.5 \Leftrightarrow \hat{z} \ge 0 \Leftrightarrow z \ge 0$이다. $\sigma(z) \ge 0.5$도 $z \ge 0$과 같으므로, 학습($\tilde{\sigma}$)과 추론(σ)의 함수가 달라도 0.5 임계값 판정은 모든 z에서 같다. 달라지는 것은 출력 확률 값의 보정(calibration)뿐이다.

5.3. Data Partitioning and Secure Training

세 기관은 동일한 환자 집합에 대해 중등도 이상 폐쇄성 수면무호흡증(AHI ≥ 15) 위험 예측 모델을 공동 학습한다. 특성은 14개이며 기관별로 Table 6과 같이 분할된다. 수면 잠복기(sleep latency)는 특성 비교 실험에서 제외했다.

Table 6. 기관별 특성 분할. ODI는 산소포화도 하강 이벤트 횟수, desat 지속 폭은 하강 이벤트 1회의 평균 지속시간과 평균 하강 폭이다.

기관 (역할)	보유 특성	파라미터
P_1 Hospital A (산소포화도)	평균 SpO2, 평균 심박수, ODI, mean_desat_duration, mean_desat_drop	w_1 (5개) + b
P_2 Sleep lab (PSG)	총 수면시간, 수면 효율, 깊은 수면 비율, WASO + 라벨	w_2 (4개)
P_3 Hospital C (외래)	나이, 성별, BMI, 목둘레, ESS	w_3 (5개)

각 미니배치에서 다음 단계가 반복된다(Algorithm 1, Appendix A).

1. **로컬 순전파:** 기관 i 는 $s_i = X_i w_i$ (+b, i = 1)를 평문으로 계산하고, 노이즈 조각 $n_i \sim N(0, \sigma^2_{DP}/K \cdot I)$를 로컬에서 뽑는다.
2. **비밀분산 입력:** s_i 와 n_i 를 SPU 에 입력하고, P_2는 배치 라벨 y 를 입력한다. 입력 시점에 ABY3 share 로 분할되어 다른 기관은 무작위 share 만 받는다.
3. **MPC 연산:** SPU 내부에서 $z = \Sigma_i s_i \rightarrow \hat{z} \rightarrow \tilde{\sigma}(\hat{z}) \rightarrow g \rightarrow \tilde{g} = g + \Sigma_i n_i$ 를 share 상태로 계산한다. z, 손실 L, 노이즈 합은 평문으로 복원되지 않는다.
4. **그래디언트 공개:** $\tilde{g}$ 를 각 기관 i 에게만 공개한다. s_i 가 z 의 덧셈 항이므로 $\partial L/\partial s_i = g$ 이며 모든 기관이 같은 $\tilde{g}$ 를 받는다.
5. **로컬 역전파:** 기관 i 는 $\nabla_{w_i} = X_i^T \tilde{g}$ 를 계산해 Adam 으로 w_i 를 갱신한다. X_i 가 필요하므로 반드시 로컬에서 수행한다.

평가 시에는 테스트 표본의 s_i와 라벨을 같은 방식으로 SPU에 넣어 정확도 mean(1[z > 0] = y)를 계산하고, 그 스칼라만 공개한다.

5.4. Encrypted Inference

추론은 학습과 분리되며 외부 클라이언트의 키로만 복호화할 수 있다(Algorithm 2, Appendix B). 학습이 끝나면 각 기관의 가중치와 표준화 통계를 하나의 HEaaN2용 모델 파일로 내보내되, 병원 i에는 자기 가중치 행만, 클라이언트에는 특성 이름·인덱스·표준화 통계만 배포한다.

1. 클라이언트는 CKKS 키를 생성하고, 표준화한 특성 블록 x_i 를 암호화해 P_i 에 보낸다.
2. 기관 i 는 평문 가중치 w_i 와 $Enc(x_i)$로 $Enc(s_i)$를 계산해(cMul, Add) 클라이언트에 돌려준다. P_1은 편향 b 를 더한다.
3. 클라이언트가 $Enc(s_i)$를 암호문 상태로 합산해 Enc(z)를 얻는다. 병원 간 통신과 암호문 간 곱셈은 없다.
4. 클라이언트가 sk_{cl} 로 z 를 한 번만 복호화하고 σ(z)를 평문으로 적용한다.

합산 뒤에 한 번만 복호화하므로 클라이언트는 기관별 s_i를 보지 못하며, 이는 기관별 가중치 추정을 어렵게 한다.

5.5. Deployment

세 기관은 각자 독립 프로세스에서 같은 학습 프로그램을 실행하며, 조율하는 드라이버는 없다(SecretFlow 프로덕션 모드). 기관당 포트는 두 개로, 하나는 PYU 객체를 SPU나 다른 기관으로 옮기는 SecretFlow 노드 간 통신(gRPC), 다른 하나는 ABY3 메시지를 교환하는 SPU 런타임 링크(brpc)이다. 각 기관은 자기 데이터 파일만 읽고, 열 단위 표준화, 가중치, Adam 상태를 자기 프로세스에만 둔다. 미니배치 순서는 세 기관이 공유하는 공개 시드에서 생성되어 통신 없이 같은 배치를 쓴다. 학습이 끝나면 각 기관은 자기 가중치와 표준화 통계만 저장한다.

6. Privacy Analysis

6.1. Plaintext Exposure

학습과 추론 전 과정에서 원시 특성, 결합 logit, 손실, 추론 입력·출력은 소유자 외의 주체에게 평문으로 노출되지 않으며, 라벨은 P_2 밖으로 평문 노출되지 않는다(Table 7). 이 분석은 다음 두 사실에 근거한다.

- **Fact 1:** CKKS 는 IND-CPA 안전성을 가지므로, sk_{cl} 이 없는 병원은 추론 암호문에서 정보를 얻지 못한다.
- **Fact 2:** ABY3 에서 오염된 기관이 1 개 이하이면 단일 기관의 SPU 뷰는 공개된 값만으로 시뮬레이션할 수 있다.

Table 7. 단계별 평문 노출 범위.

단계	값	평문으로 보는 주체	그 외 주체가 받는 형태
학습	원시 특성 X_i, 가중치 w_i, 편향 b	P_i (b는 P_1)	전송 없음
학습	로컬 logit s_i, 노이즈 조각 n_i	P_i	SPU share
학습	라벨 y	P_2 (원본 보유)	SPU share
학습	결합 logit z, 예측 $\hat{y}$, 손실 L, 노이즈 합 Σn_i	없음	SPU 내부 share
학습	그래디언트 $\tilde{g} = g + \Sigma n_i$ (표본별)	각 기관	공개 전 SPU 내부에서 노이즈 합산
학습	테스트 정확도 (스칼라)	모든 기관	평가 시점마다 1개 공개
학습	표본 수, 배치 인덱스	모든 기관	공개 메타데이터 (공개 시드)
추론	클라이언트 특성 x_i	클라이언트	병원은 CKKS 암호문만
추론	병원 가중치 w_i	P_i	클라이언트에 전송 안 됨
추론	s_i	없음	병원은 $Enc(s_i)$를 만들고 클라이언트는 합산만 함
추론	z, 위험 확률 $\hat{y}$	클라이언트	병원은 암호문만
추론	표준화 평균·표준편차	클라이언트	모델 파일로 배포 (집계 통계)

6.2. Gradient Path and Label DP

$\tilde{g}$는 소유자 외 기관이 받는 유일한 표본 단위 학습 값이다. 식 (3)에서 $|\hat{z}| \le 4$일 때 $\hat{y} = \tilde{\sigma}(\hat{z})$는 대부분 (0, 1) 안에 있으므로 노이즈 없는 g의 부호는 라벨과 직결된다. 본 시스템은 노이즈를 공개 전에 SPU 내부에서 더하므로, 어떤 기관도 노이즈 없는 g를 보지 않는다.

Proposition 1. 오염된 기관이 P_1 또는 P_3 하나이고 SPU가 Fact 2를 만족할 때, E 에폭 학습 동안 그 기관이 보는 $\tilde{g}$의 수열은 학습 라벨에 대해 ρ-zCDP이며 $\rho = E/(2B^2\sigma^2_{\text{eff}})$, $\sigma^2_{\text{eff}} = \sigma^2_{DP}\,(K-1)/K$이다.

근거. 한 표본의 라벨이 0과 1 사이에서 바뀌면 그 표본이 속한 배치의 $\tilde{g}$에서 해당 좌표만 1/B 바뀌므로 L2 민감도는 $\Delta = 1/B$이다. 오염된 기관은 자기 조각 n_i를 알기 때문에 그 기관에 대한 유효 노이즈는 나머지 K − 1개 조각의 합 $N(0, \sigma^2_{\text{eff}})$이다. 각 표본은 에폭마다 정확히 한 배치에 들어가므로 Gaussian 메커니즘이 E번 합성되고, 가중치 갱신과 다음 단계의 s_i는 이전 공개 값의 후처리이다. 표본 추출에 의한 증폭은 적용하지 않았다.

B = 256, E = 100, $\sigma_{DP} = 0.01$이면 $\sigma_{\text{eff}} = 0.0082$, 한 에폭의 $\rho = 0.114$ ($\delta = 10^{-5}$에서 $\varepsilon \approx 2.4$), 전체 $\rho = 11.4$로 **$\varepsilon \approx 34.4$ ($\delta = 10^{-5}$)**이다. 따라서 현재 설정의 형식적 보장은 약하다. 같은 B, E에서 $\varepsilon = 8$과 $\varepsilon = 4$를 얻으려면 σ_{DP}를 각각 약 0.033, 0.062로 키워야 하며, 이때의 정확도는 아직 측정하지 않았다(Sect. 8.2). P_2는 라벨 원본을 보유하므로 이 분석의 대상이 아니다.

6.3. Other Released Values

손실 L은 SPU 내부에서만 계산되고 공개되지 않는다. 평가 시점마다 공개되는 테스트 정확도는 학습 표본과 겹치지 않는 테스트 라벨의 집계 스칼라 하나이며, Proposition 1의 범위에는 포함하지 않았다. 표본 수와 배치 인덱스는 환자 정렬 이후의 공개 메타데이터이다.

6.4. Inference

병원은 $\text{Enc}(x_i)$와 $\text{Enc}(s_i)$만 다루며 sk_{cl}이 없으므로 이를 복호화할 수 없다(Fact 1). 클라이언트는 합산된 z만 복호화하고 w_i와 s_i는 보지 못한다. 클라이언트가 받는 표준화 통계는 특성별 평균·표준편차라는 집계 값이다. 반복 질의로 가중치를 추정하는 모델 추출 공격은 Sect. 4.2에서 범위 밖으로 두었다.

7. Experiments

7.1. Experiment Setup

Dataset. NSRR (Zhang et al., 2018)의 SHHS1 PSG 요약 통계와 이벤트 주석에서 추출한 desat 특성. 이벤트 주석이 있는 참가자로 한정한 환자 1명당 1행, n = 5,356 (양성 45.0%).

Label / Split. AHI ≥ 15 이진 분류. 80/20 무작위 분할(train 4,284, test 1,072, test 양성 465).

Training. SecretFlow SPU, ABY3, 식 (2)–(3)의 그래디언트, 기관별 Adam, SPU 내부 노이즈(Table 8). 세 기관은 한 머신에서 독립 프로세스로 실행했고 루프백 주소로 통신했다.

Baseline. 같은 분할에서 train으로 표준화를 맞춘 평문 로지스틱 회귀(scikit-learn, BCE).

Table 8. 하이퍼파라미터와 실행 환경.

항목	값
배치 B / 에폭 E	256 / 100 (에폭당 16 배치)
옵티마이저	Adam, lr 0.01, β (0.9, 0.999)
σ_{DP}	0.01 (기관별 조각 $\sigma_{DP}/\sqrt{3}$)
분할 / 시드	80/20, 분할 시드 42, 학습 시드 0
MPC	SecretFlow 1.13, SPU 0.9.4, ABY3, FM128
하드웨어	WSL2 Ubuntu, 12 vCPU, 11 GB RAM

7.2. Training: Security vs. Accuracy

SPU 학습 모델은 정확도 0.891, AUC 0.960으로 같은 분할의 평문 학습 대비 정확도 0.6%p, AUC 0.005 낮았으며, 부트스트랩 95% 구간이 겹친다(Table 9). 같은 테스트 표본에서 두 모델의 예측 클래스는 97.5% 일치했다. 이 차이와 맞바꾼 보안 성질은 Table 7과 같다.

Table 9. 학습 방식별 성능 (test n = 1,072, 임계값 0.5). 괄호는 부트스트랩 95% 구간(1,000회).

Model	Accuracy	AUC	Sensitivity	Specificity
평문 (scikit-learn, BCE)	0.897 (0.88–0.91)	0.965 (0.96–0.97)	0.865 (0.83–0.89)	0.923 (0.90–0.94)
SPU, BCE형 그래디언트 + clip + SPU 내부 DP	0.891 (0.87–0.91)	0.960 (0.95–0.97)	0.854 (0.82–0.89)	0.919 (0.89–0.94)

7.3. Ablation

이전 구현(MSE 자동 미분 그래디언트, 공개 후 노이즈)은 평문 대비 약 6%p 낮았다. 원인을 분리하기 위해 같은 분할에서 그래디언트 형태와 노이즈 위치를 바꿔 학습했다(Table 10, 모두 $\sigma_{DP} = 0.01$).

Table 10. Ablation (SPU, 최종 에폭 test 정확도).

그래디언트	노이즈 위치	E	최종	최고 (에폭)
MSE 자동 미분	공개 후	20	0.825	0.825 (20)
$\tilde{\sigma}'$ 하한, clip 없음	공개 후	100	0.719	0.833 (50)
BCE형 + clip	공개 후	100	0.884	0.900 (60)
BCE형 + clip	SPU 내부	100	0.891	0.895 (60)

차이의 대부분은 그래디언트 형태에서 나왔다. $\tilde{\sigma}'$에 하한만 둔 변형은 50 에폭 이후 logit이 발산해 정확도가 0.833에서 0.719로 떨어졌으며, 이는 Sect. 5.2의 양의 되먹임과 일치한다. clip을 적용한 BCE형 그래디언트는 40 에폭 이후 0.88–0.90에서 안정적이었다. 노이즈 위치를 공개 후에서 SPU 내부로 옮겨도 정확도는 거의 변하지 않았으므로, 보호 강화가 정확도 비용 없이 가능했다. MSE 행은 20 에폭만 실행해 다른 행과 직접 비교하기 어렵다.

7.4. Training Cost

100 에폭 학습은 624–644초(에폭당 약 6.3초, 배치당 약 0.4초)가 걸렸다. 세 프로세스가 한 머신의 루프백으로 통신했으므로 기관 간 실제 네트워크 지연은 반영되지 않았으며, 기관 간 송수신 바이트는 측정하지 않았다.

7.5. Inference: HE Overhead vs. Plaintext

학습된 가중치를 모델 파일로 내보낸 뒤 그 파일만으로 평문 추론을 다시 수행하면 test 정확도 0.891로 학습 시 평가와 일

치한다. CKKS 추론에서는 같은 가중치로 예측 일치율, logit 오차, 지연, 통신량을 측정해야 한다(Table 11). 병원 측 연산은 cMul과 Add뿐이어서 relinearization 키가 필요 없고 곱셈 깊이는 1이다. 다만 x_i의 값을 한 암호문의 slot에 넣으면 내적 합산에 rotation과 Galois 키가 필요하므로, 인코딩 방식(slot packing / 특성별 암호문 / 계수 packing)을 정해 함께 기재한다.

Table 11. 추론 단계 측정 항목. CKKS 파라미터(N, 모듈러스, scale, 보안 수준)를 함께 기재한다.

측정 항목	평문	CKKS
정확도 / AUC	0.891 / 0.960	측정 예정
예측 클래스 일치율	기준	측정 예정
logit 오차 $\lvert z_{CKKS} - z_{plain} \rvert$	–	측정 예정
1건 종단 간 지연	측정 예정	측정 예정
요청 크기 (클라이언트 → 병원)	14개 실수	측정 예정
응답 크기 (병원 → 클라이언트)	실수 3개	측정 예정
키 크기 (pk, Galois 키)	–	측정 예정

7.6. Decision Threshold

선별 용도에서는 민감도가 중요하므로 0.5 외의 임계값도 보고한다. train에서 Youden 지수를 최대화한 임계값은 0.39였고, test에서 민감도 0.905, 특이도 0.868, 정확도 0.884였다(Table 12). AUC가 임계값과 무관하게 0.960이므로 운영 목적에 맞춰 임계값을 고를 수 있다.

Table 12. 임계값별 test 성능 (SPU 모델).

임계값	민감도	특이도	정확도
0.50	0.854	0.919	0.891
0.39 (train Youden)	0.905	0.868	0.884
0.29 (train 민감도 ≥ 0.95)	0.938	0.817	0.869

8. Discussion and Limitations

8.1. Feasibility on Wearable Devices

ECG 원신호 기반 연구가 더 높은 정확도를 보이는 것은 사실이지만, 그 입력은 100 Hz로 밤새 연속 기록한 ECG이다 (Wang et al., 2019). Galaxy Watch의 ECG 앱(FDA K201168)은 30초 정지 측정 단일 리드 기록이며 (U.S. FDA, 2020), FDA De Novo 허가를 받은 Samsung 수면무호흡 기능은 PPG 유래 SpO2와 수면 시작·종료 정보를 입력으로 10일 이내 2박의 측정으로 판정한다 (U.S. FDA, DEN230041). 따라서 워치 환경의 현실적 입력은 SpO2·심박·수면 구조의 요약값이다. 단, 본 연구의 특성은 PSG에서 산출한 값이므로 워치 측정값과 오차 특성이 다르다.

8.2. Limitations

- **DP 예산:** 현재 $\sigma_{DP} = 0.01$ 의 예산은 $\varepsilon \approx 34.4$ 로 약하다. 더 큰 σ_{DP}에서의 정확도와, 표본 추출 증폭을 반영한 산정이 필요하다.
- **실험 설계:** SPU 모델의 표준화 통계는 test를 포함한 각 기관의 전체 행에서 계산했다. 그래디언트 형태와 에폭 수는 test 정확도를 보며 정했고, 각 설정을 시드 하나로 한 번씩 학습했다. 검증셋 분리와 여러 시드 반복이 필요하다.
- **환자 정렬:** 구현은 세 기관 파일의 행 순서가 같다고 가정한다. 실제 운영에서는 PSI로 정렬해야 한다.
- **보안 가정:** ABY3는 honest-majority, semi-honest 가정이며, 실험은 TLS 없는 루프백 통신이었다.
- **입력 데이터:** PSG 유래 특성이므로 워치 측정 데이터에서의 검증이 남아 있다.

9. Conclusion

본 논문은 중앙 서버 없이 3개 병원이 수면무호흡증 예측 모델을 공동 학습하고, 외부 클라이언트에 CKKS 암호화 추론을 제공하는 수직 연합학습 시스템을 제시했다. 세 기관은 독립 프로세스로 실행되며 기관당 두 개의 포트로만 통신한다. 원시 특성, 결합 logit, 손실, 추론 입출력은 소유자 밖으로 평문 노출되지 않고, 라벨은 산출 기관 밖으로 평문 노출되지 않는다. 소유자 외 기관이 받는 표본 단위 값은 SPU 내부에서 노이즈를 더한 그래디언트뿐이며, 그 라벨 DP 예산을 산정했다. clip을 적용한 BCE형 그래디언트로 SPU 학습은 평문 대비 정확도 0.6%p, AUC 0.005 차이에 그쳤다. 남은 과제는 DP 예산을 낮춘 설정의 성능 측정, CKKS 추론 오버헤드 측정(Table 11), 검증셋·다중 시드 실험, PSI 기반 환자 정렬, 워치 데이터 검증이다.

Impact Statement

본 연구는 여러 의료기관이 환자 원본 데이터를 공유하지 않고 수면무호흡증 위험 예측 모델을 공동 학습하는 방법을 다룬다. 제안 시스템은 임상 진단 기기가 아니며, 보고된 성능은 SHHS1 PSG 요약 통계에서 얻은 것으로 워치 측정 데이터나 다른 집단에서의 성능을 보장하지 않는다. 또한 Sect. 6.2의 DP 예산은 현재 설정에서 약하므로, 실제 적용 전에 노이즈 수준과 프라이버시 예산을 함께 정해야 한다.

References

Abadi, M. et al. Deep learning with differential privacy. In ACM CCS 2016, pp. 308–318, 2016.

Bun, M. and Steinke, T. Concentrated differential privacy: Simplifications, extensions, and lower bounds. In TCC 2016, 2016.

Chang, H.-Y., Yeh, C.-Y., Lee, C.-T., and Lin, C.-C. A sleep apnea detection system based on a one-dimensional deep convolution neural network model using single-lead electrocardiogram. Sensors, 20(15):4157, 2020.

Chen, D., Qu, H., and Xu, G. AegisFL: Efficient and flexible privacy-preserving Byzantine-robust cross-silo federated learning. In ICML, PMLR 235, 2024.

Cheon, J. H., Kim, A., Kim, M., and Song, Y. Homomorphic encryption for arithmetic of approximate numbers. In ASIACRYPT 2017, pp. 409–437, 2017.

Dwork, C. and Roth, A. The algorithmic foundations of differential privacy. Foundations and Trends in Theoretical Computer Science, 9(3–4):211–407, 2014.

Fu, C. et al. Label inference attacks against vertical federated learning. In USENIX Security 2022, pp. 1397–1414, 2022.

Ghazi, B., Golowich, N., Kumar, R., Manurangsi, P., and Zhang, C. Deep learning with label differential privacy. In NeurIPS 2021, 2021.

Hardy, S. et al. Private federated learning on vertically partitioned data via entity resolution and additively homomorphic encryption. arXiv:1711.10677, 2017.

Levy, J., Álvarez, D., Del Campo, F., and Behar, J. A. Deep learning for obstructive sleep apnea diagnosis based on single channel oximetry. Nature Communications, 14:4881, 2023.

Li, O. et al. Label leakage and protection in two-party split learning. In ICLR, 2022.

Luo, X., Wu, Y., Xiao, X., and Ooi, B. C. Feature inference attack on model predictions in vertical federated learning. In ICDE 2021, pp. 181–192, 2021.

Ma, J. et al. SecretFlow-SPU: A performant and user-friendly framework for privacy-preserving machine learning. In USENIX ATC 2023, 2023.

Mohassel, P. and Rindal, P. ABY3: A mixed protocol framework for machine learning. In ACM CCS 2018, pp. 35–52, 2018.

Mortazavi, E., Tarvirdizadeh, B., Alipour, K., and Ghamari, M. Deep learning approaches for assessing pediatric sleep apnea severity through SpO2 signals. Scientific Reports, 14:22696, 2024.

Nnamdi, M. C. et al. KindSleep: Knowledge-informed diagnosis of

obstructive sleep apnea from oximetry. arXiv:2603.04755, 2026.

Retamales, G. et al. Towards automatic home-based sleep apnea estimation using deep learning. npj Digital Medicine, 7:144, 2024.

Samsung Electronics. Samsung Health Monitor ECG App Instructions for Use.

U.S. FDA. 510(k) K201168: ECG Monitor App, Samsung Electronics, 2020.

U.S. FDA. De Novo classification request for Sleep Apnea Feature (DEN230041), Samsung Electronics.

Wang et al. Sleep apnea detection from a single-lead ECG signal with automatic feature-extraction through a modified LeNet-5 convolutional neural network. PeerJ, 7:e7731, 2019.

Wu, Y., Xing, N., Chen, G., Dinh, T. T. A., Luo, Z., Ooi, B. C., Xiao, X., and Zhang, M. Falcon: A privacy-preserving and interpretable vertical federated learning system. PVLDB, 16(10):2471–2484, 2023.

Yang, Q., Liu, Y., Chen, T., and Tong, Y. Federated machine learning: Concept and applications. ACM TIST, 10(2), 2019a.

Yang, S., Ren, B., Zhou, X., and Liu, L. Parallel distributed logistic regression for vertical federated learning without third-party coordinator. arXiv:1911.09824, 2019b.

Zhang, G.-Q. et al. The National Sleep Research Resource: Towards a sleep data commons. JAMIA, 25(10):1351–1358, 2018.

A. Secure Vertical Logistic Regression Training

Algorithm 1은 현재 구현의 순서를 그대로 옮긴 것이다. 노이즈는 공개 전에 SPU 내부에서 더해진다.

```
Algorithm 1  Secure vertical logistic regression training
Input: feature blocks {X_i} at P_i, labels y at P_2, batch size B, epochs E, noise σ_DP
Output: local weights {w_i}, bias b (held by P_1)
for epoch = 1, ..., E do                          ▷ batch order from a shared public seed
  for each mini-batch do
    for i = 1, ..., K in parallel do
      s_i ← X_i w_i (+ b if i = 1)                ▷ local, plaintext
      n_i ~ N(0, σ_DP² / K · I)                   ▷ local, never revealed
    end for
    g ← SPU( Σ_i s_i → clip(·, −4, 4) → σ̃→ (σ̃− y) / B )      ▷ y input by P_2
    g̃ ← SPU( g + Σ_i n_i )                        ▷ noise added before reveal
    for i = 1, ..., K in parallel do
      w_i ← Adam(w_i, X_iᵀ reveal_to_P_i(g̃))     ▷ local update
    end for
  end for
end for                                           ▷ loss L is computed in SPU but never revealed
```

B. Encrypted Inference

```
Algorithm 2  Client-key CKKS inference
Input: client features {x_i}, client key pair (pk_cl, sk_cl), hospital weights {w_i}, bias b (P_1)
Output: risk probability ŷ (client only)
Client: for i = 1, ..., K: ct_i ← Enc(standardize(x_i), pk_cl); send ct_i to P_i
P_i:    ct(s_i) ← cMul(ct_i, w_i) and Add (P_1 also adds b); return ct(s_i)
Client: ct(z) ← Add(ct(s_1), ..., ct(s_K))    ▷ no ct-ct mult., no hospital-to-hospital traffic
Client: z ← Dec(ct(z), sk_cl); ŷ ← σ(z)        ▷ plaintext, decrypted once after the sum
```

C. Gradient Derivation

정확한 시그모이드와 BCE 손실 $L_{BCE} = -(1/B)\,\Sigma_n\,[y^{(n)} \log \sigma(z^{(n)}) + (1 - y^{(n)}) \log(1 - \sigma(z^{(n)}))]$의 그래디언트는 $\sigma' = \sigma(1 - \sigma)$에 의해 $\partial L_{BCE}/\partial z^{(n)} = (\sigma(z^{(n)}) - y^{(n)})/B$로 정리되어 σ'이 남지 않는다. 본 시스템은 이 식에서 σ를 $\tilde{\sigma}\circ\mathrm{clip}$으로 바꾼 식 (3)을 그래디언트로 직접 지정한다(JAX custom VJP). 반면 MSE 손실을 자동 미분하면 $(2/B)(\tilde{\sigma}(z) - y)\tilde{\sigma}'(z)$가 되어, $\tilde{\sigma}'(z) = 0.197 - 0.012z^2$가 0에 가까워지거나 음수가 되는 구간에서 갱신이 멈추거나 반대 방향이 된다.

결합 logit $z = \Sigma_i\, s_i$이므로 $\partial z/\partial s_i = 1$이고 모든 기관이 받는 그래디언트는 같다. 기관 i의 가중치 그래디언트는 $\nabla_{w_i} = \Sigma_n\, \tilde{g}^{(n)}\, x_i^{(n)} = X_i^{\mathsf{T}}\tilde{g}$이며, X_i가 필요하므로 로컬에서만 계산된다. 편향의 그래디언트는 $\Sigma_n\, \tilde{g}^{(n)}$이다.